UnB/ENE0154 - Inteligencia Computacional - 2025.2 - Prof. Adolfo Bauchspiess
Projeto de treinamento de RNA - 16/09/2025

Reconhecimento de Caracteres com Melhoria da Tolerância a Ruídos

Washington Marinho dos Santos *

* *170072274, Engenharia Mecatrônica UnB, 170072274@aluno.unb.br*

Abstract: This report details the development and validation of a feedforward Artificial Neural Network (ANN) for alphanumeric character recognition. The primary objective was to enhance the network's robustness against noisy data, a common challenge in practical Optical Character Recognition (OCR) applications. An incremental training methodology was employed, where sequential ANN models were trained with progressively increasing levels of noise (from 0% to 50%). The results demonstrate that the network trained with this strategy (TrN) achieved significantly superior performance in classifying noisy characters compared to a network trained solely on clean data (TrO). The comparative analysis validates that exposure to noisy data during training enhances the model's robustness and generalization capabilities, particularly at noise levels of 20% and above. This study confirms that incorporating noisy samples into the training regimen is an effective technique for building more reliable and resilient OCR systems.

Resumo: Este relatório detalha o desenvolvimento e a validação de uma Rede Neural Artificial (RNA) feedforward para reconhecimento de caracteres alfanuméricos. O objetivo principal era aumentar a robustez da rede contra dados ruidosos, um desafio comum em aplicações práticas de Reconhecimento Ótico de Caracteres (OCR). Foi empregada uma metodologia de treinamento incremental, na qual modelos ANN sequenciais foram treinados com níveis progressivamente crescentes de ruído (de 0% a 50%). Os resultados demonstram que a rede treinada com essa estratégia (TrN) alcançou um desempenho significativamente superior na classificação de caracteres ruidosos em comparação com uma rede treinada exclusivamente com dados limpos (TrO). A análise comparativa valida que a exposição a dados ruidosos durante o treinamento aumenta a robustez e as capacidades de generalização do modelo, particularmente em níveis de ruído de 20% e acima. Este estudo confirma que incorporar amostras ruidosas no regime de treinamento é uma técnica eficaz para construir sistemas OCR mais confiáveis e resilientes.

Keywords: Keywords: Artificial Neural Networks; Character Recognition; OCR; Noise Tolerance; Incremental Training; Python; Keras.

Palavras-chaves: Redes Neurais Artificiais; Reconhecimento de Caracteres; OCR; Tolerância a Ruído; Treinamento Incremental; Python; Keras.

1. INTRODUÇÃO

As Redes Neurais Artificiais (RNAs) são modelos computacionais projetadas para modelar a maneira como o cérebro humano realiza tarefas ou funções específicas de interesse, dado o a sua forma complexa de funcionamento. São capazes de aprender padrões a partir de dados e realizar tarefas complexas como classificação e reconhecimento.

Uma de suas aplicações é o Reconhecimento Óptico de Caracteres (OCR), tecnologia fundamental para a digitalização de documentos e automação de processos, pois permite transformar arquivos em dados textuais, trazendo um formato dinâmico para os dados.

Com a digitalização de dados pode-se haver problemas que comprometam a visualização exata do dado, e esses problemas são os ruídos, que podem ocorrer devido falhas, comrrompimentos e baixa qualidade. Devido o ruído, pode não ser possivel identificar o dado e não se possivel classificar corretamente e isso representa um desafio significativo para a precisão dos sistemas de OCR. Uma rede treinada apenas com dados "limpos"pode ter seu desempenho drasticamente reduzido ao se deparar com essas imperfeições.

Este projeto aborda exatamente esse problema, investigando como uma estratégia de treinamento incremental com a introdução de ruído pode melhorar a robustez de uma RNA para o reconhecimento de caracteres. A hipótese central é que, ao "ensinar"a rede a lidar com imperfeições, ela se tornará mais tolerante e generalista.



Figura 1. Exemplos de caracteres sem ruido



Figura 2. Exemplos de caracteres com ruido

2. METODOLOGIA DO PROJETO

O projeto foi desenvolvido em Python, utilizando a biblioteca Keras com TensorFlow como backend. A metodologia foi dividida em quatro etapas principais: a geração dos dados, a arquitetura da rede, o treinamento e a validação. Por questão de desempenho, foi utilizado o Google Colab para executar esse projeto.

2.1 Geração de Dados

Os dados foram gerados por um módulo auxiliar (geraChar.py). Foram criados 16 padrões de caracteres alfanuméricos "alfabeto"(0, 1, 2, 3, 4, 5, 6, 7, H, R, W, X, Y, Z, F, P), cada um representado por uma matriz de pixels de 9x7, totalizando um vetor de 63 entradas para a rede. A **Figura [1]**, mostra um exemplo de alfabeto de 16 padrões na matriz de pixel. A segunda celula de codigo do aruqivo principal OCR_ICIN_UnB.ipynb mostra o alfabeto utilizado.

A função gchar_ruido foi utilizada para introduzir um percentual de ruído nos padrões, invertendo aleatoriamente os valores dos pixels. A **Figura [2]** mostra um exemplo do alfabeto da **Figura [1]** com 20% de ruido.

Como foi utilizado o Google COlab, um possivel problema é o mudulo geraChar.py não está na mesma pasta do arquivo principal OCR_ICIN_UnB.ipynb, o que leva a alguns erros. Para contornar isso, foi adicionado uma célula de codigo no arquivo principal iniciando com a linha de codigo **%%writefile geraChar.py** e nas linhas posteriores sendo todo o codigo do modulo geraChar.py.

Com isso, não há preocupação com o modulo geraChar não ser alcançavel pelo arquivo principal, pois sempre que o for executado, criar ou subscreve o arquivo geraChar na pasta do arquivo principal.

2.2 Arquitetura da Rede Neural

A arquitetura da RNA foi definida como um modelo sequencial feedforward simples, composto por:

- Uma camada de entrada com 63 neurônios, correspondente a cada pixel do caractere.
- Uma camada oculta com 30 neurônios e função de ativação sigmoide.
- Uma camada de saída com 16 neurônios (um para cada caractere) e função de ativação sigmoide.

A função de perda utilizada foi a binary_crossentropy e o otimizador foi o adam.

2.3 Treinamento Incremental

O núcleo do experimento consistiu em treinar 6 redes neurais (N = 6) com uma estratégia incremental de ruído:

- Rede Base (TrO - Models[0]): Foi treinada exclusivamente com os caracteres originais (0% de ruído) por 800 épocas, estabelecendo uma base de conhecimento.
- Redes com Ruído (TrN - Models[1] a Models[5]): Cada rede subsequente herdou os pesos da anterior. Elas foram então submetidas a um treinamento adicional com caracteres ruidosos, em incrementos de 10% de ruído (NStep = 10), indo de 10% até 50%. Para cada nível de ruído, foram geradas 10 amostras de treino (Nnt = 10) e o ajuste foi realizado com 10 épocas.

2.4 Validação

Para a validação, todas as redes treinadas foram testadas com novos conjuntos de caracteres contendo níveis de ruído de 0% a 50%. Para cada nível de ruído, foram geradas 10 amostras de validação (Nnv = 10). A métrica de desempenho foi a porcentagem de classificações incorretas.

3. RESULTADOS E DISCUSSÃO

Os resultados do processo de validação estão consolidados no gráfico da A **Figura [3]**. A linha verde (TrO) representa o desempenho da rede base, enquanto a linha azul (TrN) representa o desempenho das redes treinadas com ruído.

A análise do gráfico revela os seguintes pontos:

- Baixo Ruído (0% e 10%): Ambas as redes apresentaram um desempenho praticamente perfeito, com taxa de erro próxima de 0%. Isso indica que o treinamento com ruído não prejudicou a capacidade da rede TrN de reconhecer caracteres limpos.
- Ponto de Inflexão (20% a 30%): A partir de 20% de ruído, a superioridade da rede TrN começa a se manifestar. Com 30% de ruído, o erro da rede TrO sobe para aproximadamente 37%, enquanto o erro da TrN se mantém significativamente menor, em torno de 24%.
- Alto Ruído (40% e 50%): Nesses níveis, o desempenho de ambas as redes degrada consideravelmente. No entanto, a rede TrN continua apresentando uma taxa de erro consistentemente menor que a TrO, validando que sua robustez é superior mesmo em condições extremas.

Os resultados confirmam a hipótese do projeto. A exposição controlada a dados imperfeitos durante o treinamento permitiu que a rede TrN aprendesse características mais resilientes e generalistas, tornando-a mais apta a lidar com as variações e ruídos encontrados em aplicações do mundo real.

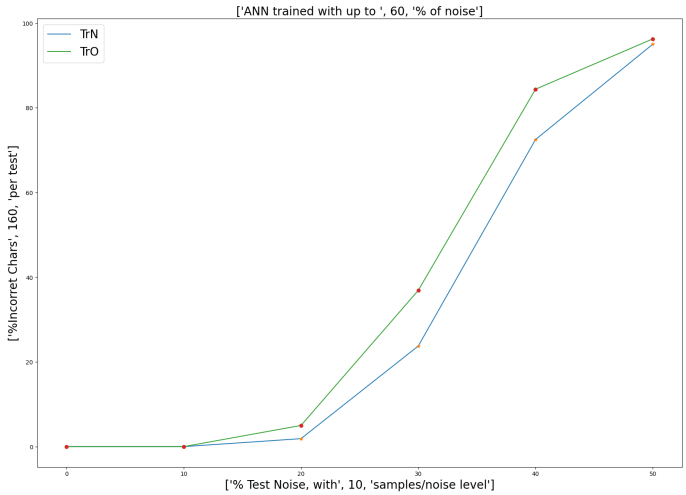


Figura 3. Resposta obtida das RNAs para a validação com ruídos

4. CONCLUSÃO

Este projeto demonstrou com sucesso a eficácia de uma estratégia de treinamento incremental com ruído para aumentar a robustez de uma Rede Neural Artificial no reconhecimento de caracteres. O modelo treinado com dados ruidosos (TrN) superou consistentemente o modelo treinado apenas com dados limpos (TrO), especialmente em níveis de ruído intermediários e altos.

A conclusão principal é que, para aplicações práticas de OCR onde a qualidade dos dados de entrada não é garantida, a incorporação de amostras ruidosas no conjunto de treinamento é uma técnica fundamental para construir modelos mais confiáveis e com maior capacidade de generalização. O experimento valida que a robustez de uma RNA não depende apenas da arquitetura, mas também da qualidade e variedade dos dados com os quais ela é treinada.

REFERÊNCIAS

Silva, I.N.; Spatti, D. H.; Flauzino, R. A.: Redes Neurais Artificiais - para Engenharia e Ciências Aplicadas, Artliber, 2016

Goodfelow, I., Bengio, Y., Courville, A. Deep Learning, MIT Press, 2016

Murphy, Kevin P.: Probabilistic Machine Learning: An Introduction, MIT Press, 2022

https://www.ene.unb.br/adolfo/Lectures/IC.html